

Baseline Clássico para Radiografias de Tórax SIIM-FISABIO-RSNA COVID-19

Felipe Freires da Costa¹, Eduardo Nobre Nogueira de Oliveira¹,
Pedro Paulo Alves dos Santos Nunes¹

¹Curso de Sistemas de Informação – UniCatólica - Centro Universitário Católica
Quixadá – CE – Brasil

Abstract. *We build a non-deep-learning baseline for four-class study-level classification of chest radiographs in the 2021 SIIM-FISABIO-RSNA COVID-19 challenge: five hand-crafted descriptor families from a classical lung mask, four classifiers and patient-grouped nested cross-validation. On a frozen hold-out, the selected model reaches a macro AUC-ROC of 0.729 (trivial: 0.500); most errors are indeterminate and atypical studies predicted as typical.*

Resumo. *Construímos um baseline sem aprendizado profundo para classificar, por estudo, radiografias de tórax em quatro classes no desafio SIIM-FISABIO-RSNA COVID-19 (2021): cinco famílias de descritores manuais de uma máscara pulmonar clássica, quatro classificadores e validação cruzada aninhada agrupada por paciente. No teste congelado, o modelo selecionado atinge AUC-ROC macro de 0,729 (trivial: 0,500); a maior parte dos erros são estudos indeterminados e atípicos preditos como típicos.*

1. Introdução

Na COVID-19, a radiografia de tórax (RX) mostra opacidades inespecíficas, em geral bilaterais, periféricas e basais [Wong et al. 2020]; o laudo padronizado as classifica em aparência típica, indeterminada, atípica ou negativa [Litmanovich et al. 2020]. O desafio SIIM-FISABIO-RSNA de 2021 adotou essas categorias em um conjunto multicêntrico anotado por radiologistas [Lakhani et al. 2023]; formulamos a tarefa como classificação em quatro classes *por estudo*. Como modelos profundos em RX tendem a aprender atalhos [DeGrave et al. 2021], é preciso um piso interpretável e medido com rigor. Contribuímos com:

- pipeline reprodutível de leitura DICOM, máscara pulmonar e cinco famílias de descritores, inclusive zonais;
- grade descritor $\times$ classificador em CV aninhada por paciente, com baseline trivial, teste congelado e ablações;
- análise de erro por classe, por modalidade (CR/DX) e por falha da máscara.

2. Trabalhos Relacionados

Máscaras pulmonares com histogramas, bordas, LBP e HOG em SVM já detectavam achados difusos na triagem de tuberculose [Jaeger et al. 2014], e descritores de textura foram aplicados à COVID-19 em RX portáteis [Hussain et al. 2020]. Muitos desses estudos, porém, usaram fontes distintas por classe e partição por imagem, o que superestima o desempenho [Roberts et al. 2021] e favorece atalhos [DeGrave et al. 2021]. Usamos rotulagem padronizada, sem classes ligadas a fontes distintas [Lakhani et al. 2023], e particionamos por paciente com CV aninhada [Varma and Simon 2006].

3. Metodologia

Dados. Código e partição congelada (semente 42): <https://github.com/FelipeFreires-Costa/COVID-19-AI-Detection-AP1>. Usamos todo o treino do desafio (6.054 estudos, 6.334 imagens, 3.261 pacientes), pois os rótulos do teste oficial não são públicos: Típico 47,2%, Negativo 27,7%, Indeterminado 17,3% e Atípico 7,8%. Com *StratifiedGroupKFold* por *PatientID*, separamos dev (4.780 estudos, 5 dobras) e teste (1.274 estudos), sem paciente em comum.

Pré-processamento. Aplicamos *Modality LUT (RescaleSlope/Intercept)* e *VOI LUT*, invertemos imagens *MONOCHROME1*, normalizamos pelos percentis 0,5–99,5, redimensionamos para 512×512 e aplicamos *CLAHE* [Zuiderveld 1994]. A máscara pulmonar segue o limiar de Otsu [Otsu 1979] com regras morfológicas, como em [Jaeger et al. 2014]: abertura, os dois maiores componentes internos e fecho convexo; quando falha, usamos uma ROI fixa (9,2% das imagens; Figura 1). Ela é dividida em seis zonas (lado $\times$ terço vertical).

Descritores, dentro da máscara: (1) *intensidade zonal* (momentos, percentis, histograma, estatísticas por zona, assimetria lateral e gradiente inferior-superior), que codifica a distribuição típica [Wong et al. 2020]; (2) *GLCM/Haralick* [Haralick et al. 1973] (7 propriedades, 3 distâncias, 4 ângulos), para a heterogeneidade do vidro fosco; (3) *LBP* uniforme invariante à rotação em 3 escalas [Ojala et al. 2002], pela invariância a mudanças monotônicas de brilho; (4) *Gabor* [Jain and Farrokhnia 1991] (4 escalas, 4 orientações); e (5) *HOG* [Dalal and Triggs 2005] no recorte pulmonar. Estudos com várias imagens usam a média.

Modelos e protocolo. Comparamos o baseline trivial (probabilidades a priori) com regressão logística, SVM-RBF, Random Forest e LightGBM [Ke et al. 2017], com pesos de classe balanceados, via *scikit-learn* [Pedregosa et al. 2011]. Imputação, padronização e PCA ficam no *pipeline*, ajustados só no treino de cada dobra. Os hiperparâmetros são escolhidos em 3 dobras internas agrupadas dentro de cada uma das 5 externas [Varma and Simon 2006]; a melhor no dev é reajustada e avaliada uma única vez no teste. Reportamos AUC-ROC e AUC-PR macro (esta mais informativa sob desbalanceamento [Saito and Rehmsmeier 2015]), acurácia balanceada, sensibilidade por classe e AUC binária pneumonia vs. negativo.

4. Resultados e Discussão

Tabela 1. AUC-ROC macro (um-contra-todos) na validação cruzada aninhada (5 dobras externas agrupadas por paciente), média $\pm$ desvio-padrão.

Descritor	Reg. Logística	SVM-RBF	Random Forest	LightGBM
Intensidade (zonal)	0.616 $\pm$ 0.011	0.623 $\pm$ 0.012	0.608 $\pm$ 0.010	0.600 $\pm$ 0.015
GLCM/Haralick	0.600 $\pm$ 0.018	0.635 $\pm$ 0.009	0.605 $\pm$ 0.009	0.615 $\pm$ 0.013
LBP	0.672 $\pm$ 0.016	0.685 $\pm$ 0.020	0.655 $\pm$ 0.016	0.653 $\pm$ 0.010
Gabor	0.666 $\pm$ 0.014	0.690 $\pm$ 0.013	0.670 $\pm$ 0.013	0.676 $\pm$ 0.009
HOG	0.677 $\pm$ 0.017	0.702 $\pm$ 0.016	0.673 $\pm$ 0.015	0.680 $\pm$ 0.013
Todas	0.688 $\pm$ 0.019	0.710 $\pm$ 0.014	0.683 $\pm$ 0.015	0.689 $\pm$ 0.008
Baseline trivial (majoritário)	0.500 $\pm$ 0.000			

A melhor família isolada foi HOG (AUC 0,702); a concatenação de todas chegou a 0,710 (Tabela 1) e, em média, SVM-RBF foi o melhor classificador. A selecionada,

Todas + SVM-RBF, teve AUC $0,710 \pm 0,014$ na CV e, no teste, AUC 0,729, AUC-PR 0,463 (trivial: 0,250), acurácia balanceada 0,412 (trivial: 0,250) e AUC binária 0,861.




Figura 1. Máscaras (verde) e fallback (vermelho).

Figura 2. ROC por classe e matriz de confusão normalizada no teste.

Ablações. A AUC foi 0,692 sem CLAHE e sem máscara e 0,710 no pipeline completo: a máscara contribuiu com +0,014 e o CLAHE com +0,007. Com regressão logística, a sensibilidade da classe Atípica foi 0,028 sem tratamento, 0,333 com pesos de classe e 0,300 com SMOTE [Chawla et al. 2002], enquanto a AUC pouco variou (0,699, 0,688, 0,681): o tratamento desloca sobretudo o limiar.

Análise de erro. No teste, 64,2% dos Indeterminados e 68,5% dos Atípicos foram preditos como Típicos (Figura 2): as categorias diferem mais pela distribuição das opacidades que pela textura [Litmanovich et al. 2020], o que descritores agregados captam só em parte. A acurácia maior no fallback (0,821 contra 0,621) é enganosa: 97,4% desses estudos têm pneumonia (contra 69,7% com máscara válida), pois opacidades densas quebram o limiar de Otsu e favorecem a classe Típico. A acurácia foi 0,665 em CR e 0,614 em DX (AUC binária 0,885 e 0,835); na permutação, HOG foi a família mais informativa.

5. Conclusão

O baseline clássico fixa o piso do projeto em AUC-ROC macro de 0,729 e acurácia balanceada de 0,412: há sinal para detectar pneumonia, mas pouco para separar as aparências atípica e indeterminada, de definição espacial. Limitações: máscara heurística, agregação por média e falta de harmonização entre equipamentos. Próximos passos: descritores regionais guiados pelas caixas de opacidade e comparação com redes profundas na mesma partição.

Referências

- Chawla, N. V., Bowyer, K. W., Hall, L. O., and Kegelmeyer, W. P. (2002). SMOTE: Synthetic minority over-sampling technique. *Journal of Artificial Intelligence Research*, 16:321–357.
- Dalal, N. and Triggs, B. (2005). Histograms of oriented gradients for human detection. In *IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, pages 886–893.
- DeGrave, A. J., Janizek, J. D., and Lee, S.-I. (2021). AI for radiographic COVID-19 detection selects shortcuts over signal. *Nature Machine Intelligence*, 3(7):610–619.

- Haralick, R. M., Shanmugam, K., and Dinstein, I. (1973). Textural features for image classification. *IEEE Transactions on Systems, Man, and Cybernetics*, SMC-3(6):610–621.
- Hussain, L., Nguyen, T., Li, H., et al. (2020). Machine-learning classification of texture features of portable chest X-ray accurately classifies COVID-19 lung infection. *BioMedical Engineering OnLine*, 19:88.
- Jaeger, S., Karargyris, A., Candemir, S., et al. (2014). Automatic tuberculosis screening using chest radiographs. *IEEE Transactions on Medical Imaging*, 33(2):233–245.
- Jain, A. K. and Farrokhnia, F. (1991). Unsupervised texture segmentation using Gabor filters. *Pattern Recognition*, 24(12):1167–1186.
- Ke, G., Meng, Q., Finley, T., et al. (2017). LightGBM: A highly efficient gradient boosting decision tree. In *Advances in Neural Information Processing Systems 30 (NIPS)*, pages 3149–3157.
- Lakhani, P., Mongan, J., Singhal, C., et al. (2023). The 2021 SIIM-FISABIO-RSNA machine learning COVID-19 challenge: Annotation and standard exam classification of COVID-19 chest radiographs. *Journal of Digital Imaging*, 36(1):365–372.
- Litmanovich, D. E., Chung, M., Kirkbride, R. R., Kicska, G., and Kanne, J. P. (2020). Review of chest radiograph findings of COVID-19 pneumonia and suggested reporting language. *Journal of Thoracic Imaging*, 35(6):354–360.
- Ojala, T., Pietikäinen, M., and Mäenpää, T. (2002). Multiresolution gray-scale and rotation invariant texture classification with local binary patterns. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 24(7):971–987.
- Otsu, N. (1979). A threshold selection method from gray-level histograms. *IEEE Transactions on Systems, Man, and Cybernetics*, 9(1):62–66.
- Pedregosa, F., Varoquaux, G., Gramfort, A., et al. (2011). Scikit-learn: Machine learning in Python. *Journal of Machine Learning Research*, 12:2825–2830.
- Roberts, M., Driggs, D., Thorpe, M., et al. (2021). Common pitfalls and recommendations for using machine learning to detect and prognosticate for COVID-19 using chest radiographs and CT scans. *Nature Machine Intelligence*, 3(3):199–217.
- Saito, T. and Rehmsmeier, M. (2015). The precision-recall plot is more informative than the ROC plot when evaluating binary classifiers on imbalanced datasets. *PLoS ONE*, 10(3):e0118432.
- Varma, S. and Simon, R. (2006). Bias in error estimation when using cross-validation for model selection. *BMC Bioinformatics*, 7:91.
- Wong, H. Y. F., Lam, H. Y. S., Fong, A. H.-T., et al. (2020). Frequency and distribution of chest radiographic findings in patients positive for COVID-19. *Radiology*, 296(2):E72–E78.
- Zuiderveld, K. (1994). Contrast limited adaptive histogram equalization. In Heckbert, P. S., editor, *Graphics Gems IV*, pages 474–485. Academic Press.

Uso de IA generativa: apoio em dúvidas de código, revisão, tradução e formulação de trechos; conteúdo e referências revisados pelo grupo.